# HANDWRITTEN TEXT OCR

Patrocli Riccardo

# INDICE

1) Introduzione
2) Dataset e suddivisione dei dati
3) Architettura CNN
4) Pipeline di riconoscimento
5) Tuning della segmentazione
6) Tuning del riconoscimento
7) Risultati e valutazione
8) Difficoltà e sviluppi futuri

# INTRODUZIONE

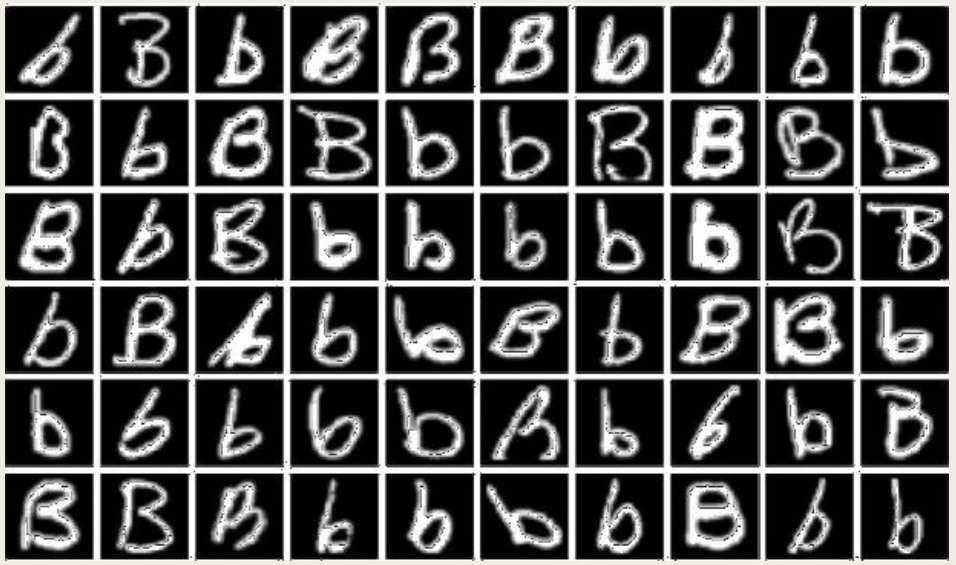
**OBIETTIVO:** Riconoscere caratteri, parole e brevi testi manoscritti

**APPROCCIO:** Elaborazione delle immagini, CNN e controllo linguistico e contestuale

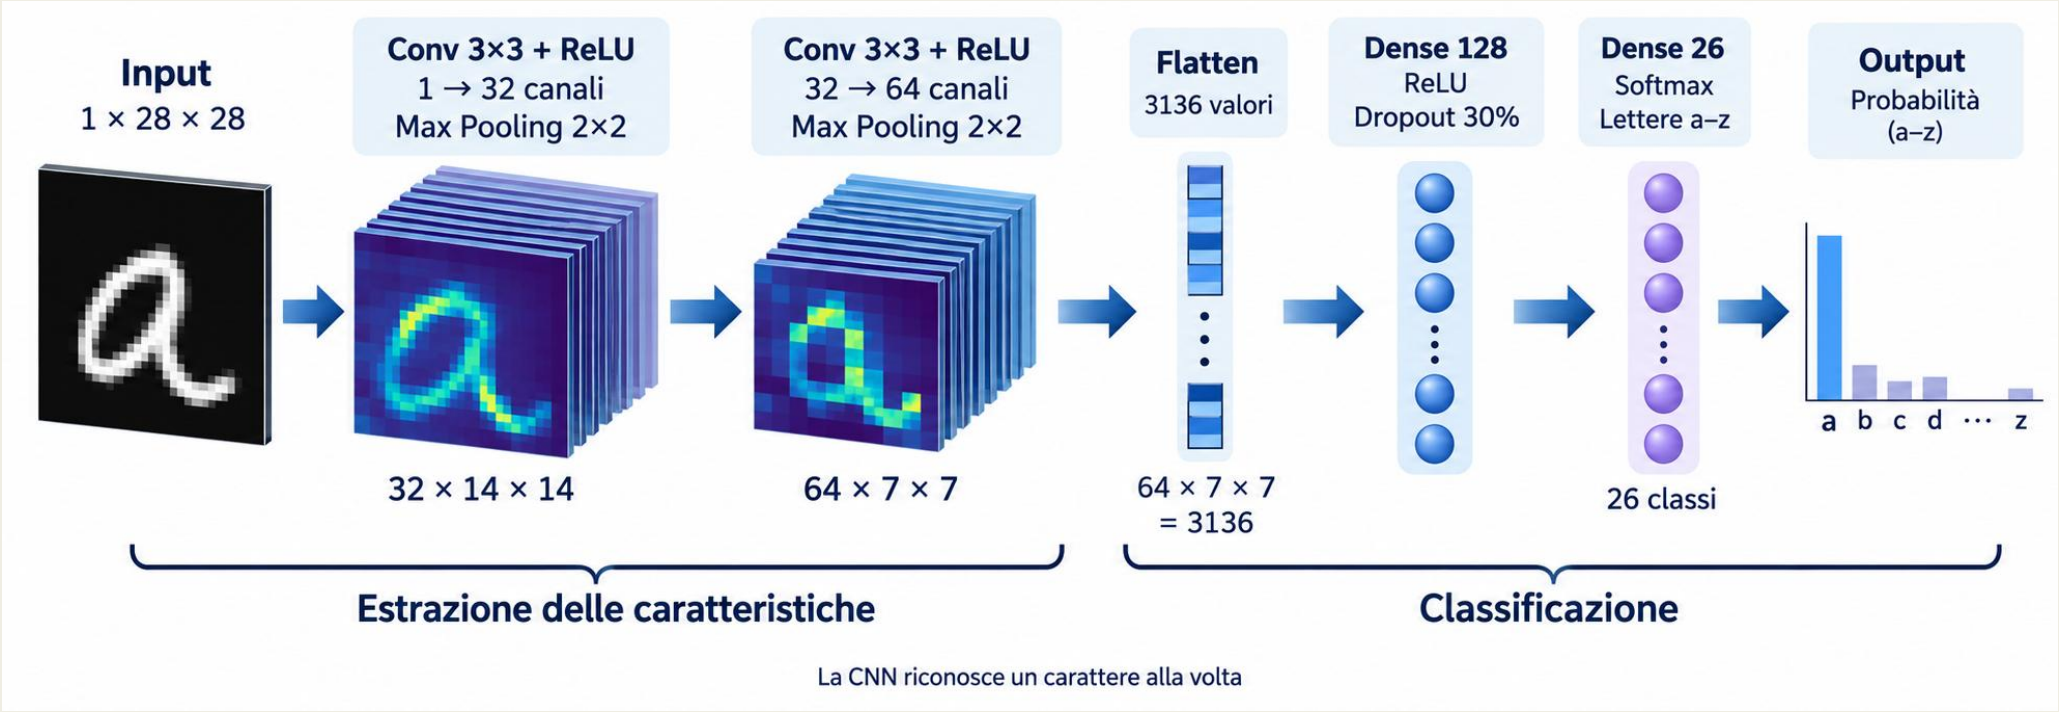


# DATASET - EMNIST

| CARATTERISTICHE | SUDDIVISIONE DATI | PREPROCESSING |
|---|---|---|
| • Dataset di caratteri manoscritti<br>• Immagini in scala di grigi<br>• Immagini 28x28 pixel<br>• Classificazione di 26 lettere dell'alfabeto | • Training set: 90%<br>• Validation set: 10%<br>• Test set separato | • Normalizzazione valori pixel<br>• Preparazione immagini per CNN<br>• Correzione orientamento |



# ARCHITETTURA CNN



# PIPELINE RICONOSCIMENTO



# TUNING SEGMENTAZIONE

Obiettivo: Isolare i caratteri preservando i tratti utili.

| PARAMETRO | VARIABILI | CONTROLLO | COMPROMESSO |
|---|---|---|---|
| Area e altezza minime | `minimum_area` `minimum_height` | Eliminazione componenti piccole | Rimozione del rumore ↔ Conservazione dettagli |
| Soglia di larghezza | `width_limit` | Individuazione lettere unite | Separazione lettere collegate ↔ Evitare di spezzare lettere larghe |
| Penalità dei tagli | `SEGMENT_SPLIT_PENALTY` | Accettazione delle separazioni proposte, con supporto della CNN | Più separazioni ↔ Prudenza |
| Soglia sugli spazi | `word_gap_threshold` | Raggruppamento dei caratteri in parole | Evitare parole unite ↔ Evitare divisioni eccessive |

Metodo: Osservare i riquadri, modificare i parametri e confrontare i risultati.

# TUNING RICONOSCIMENTO

Obiettivo: Gestire l'incertezza della CNN e migliorare la ricostruzione delle parole.

| PARAMETRO | VARIABILI | CONTROLLO | COMPROMESSO |
|---|---|---|---|
| Soglia di confidenza | `confidence_threshold` | Segnalazione dei caratteri incerti | Individuare più casi dubbi ↔ Evitare segnalazioni eccessive |
| Alternative per carattere | `top_k` | Numero di lettere candidate per ogni posizione | Recuperare alternative corrette ↔ Aumentare le combinazioni da valutare |
| Ampiezza beam search | `beam_width` | Numero di candidati di parola mantenuti | Esplorare più ipotesi ↔ Contenere il costo di elaborazione |
| Distanza massima di modifica | `max_edit_distance` | Numero massimo di modifiche ammesse nella ricerca delle correzioni | Recuperare errori più complessi ↔ Evitare suggerimenti poco pertinenti |

Metodo: Confrontare testo OCR e testo finale, verificando sia gli errori recuperati, sia le correzioni improprie.

# RISULTATI

La qualità finale dipende dalla segmentazione, dalla classificazione e dalla correzione linguistica.

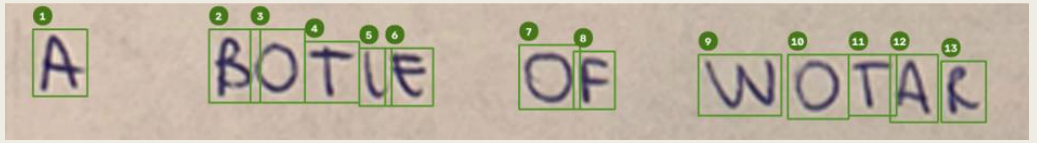
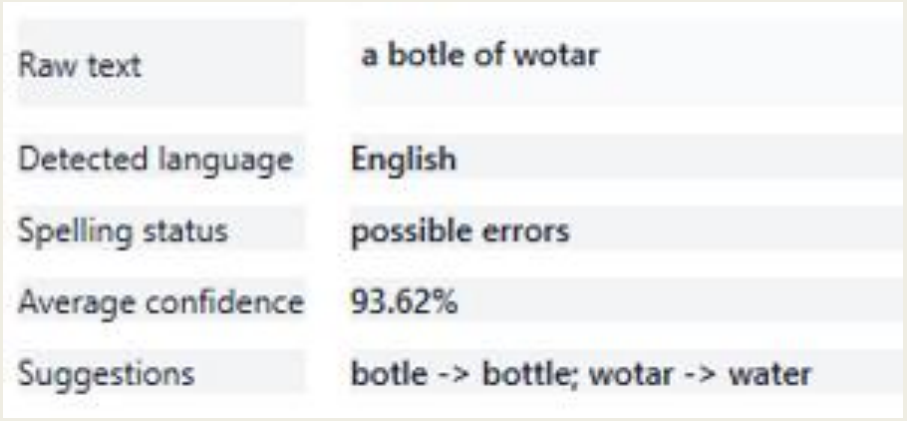
1) RICONOSCIMENTO CORRETTO

| | |
|---|---|
| IMMAGINE SEGMENTATA |   |
| OCR GREZZO | Raw text: the cat is on tne tagre<br>Detected language: English<br>Spelling status: possible errors<br>Average confidence: 92.51%<br>Suggestions: tne -> the; tagre -> table |
| TESTO FINALE | **the cat is on the table** |

# RISULTATI

La qualità finale dipende dalla segmentazione, dalla classificazione e dalla correzione linguistica.

2) CORREZIONE RIUSCITA

| | |
|---|---|
| IMMAGINE SEGMENTATA |  |
| OCR GREZZO |  |
| TESTO FINALE |  |

# RISULTATI

La qualità finale dipende dalla segmentazione, dalla classificazione e dalla correzione linguistica.

3) CASO PROBLEMATICO

| | |
|---|---|
| IMMAGINE SEGMENTATA |   |
| OCR GREZZO | Raw text: la barca ra al poqo<br>Detected language: Italian + English<br>Spelling status: possible errors<br>Average confidence: 92.97%<br>Suggestions: poqo -> pogo |
| TESTO FINALE | **la barca ra al pogo** |

# DIFFICOLTÀ E SVILUPPI FUTURI

| DIFFICOLTÀ | POSSIBILE SVILUPPO |
|---|---|
| **Lettere unite o frammentate:** difficoltà nell'isolare correttamente i caratteri | Migliorare la segmentazione e valutare modelli che riconoscano intere sequenze |
| **Grafie diverse da EMNIST:** forme, inclinazioni e spessori differenti | Ampliare il dataset locale |
| **Lettere visivamente simili:** ambiguità nella classificazione | Analizzare la matrice di confusione e aumentare gli esempi per le classi problematiche |
| **Correzioni linguistiche improprie:** parole rare o straniere possono essere penalizzate | Ampliare i dizionari e migliorare l'uso del contesto |

# GRAZIE